

Análise preditiva de investimentos nos dados do CNPq

Predictive analysis of investments in CNPq data

Felipe Barros Gomes*

RESUMO

PALAVRAS-CHAVE: Ciência de dados; Mineração de dados; Inteligência Artificial.

ABSTRACT

KEYWORDS: Data science; Data mining; Artificial Intelligence.

1 INTRODUÇÃO

A pesquisa científica é a aplicação prática de um conjunto de procedimentos objetivos, utilizados por um pesquisador para o desenvolvimento de um experimento, a fim de produzir um novo conhecimento, além de integrá-lo àqueles pré-existentes. A pesquisa amplia o conhecimento humano, permitindo compreender melhor a realidade e resolver problemas concretos, desenvolve a ciência produzindo novas teorias, hipóteses e tecnologias, além de aumentar nossa capacidade de aprender continuamente.

Um dos principais meios de fomentar a pesquisa no Brasil é por meio do apoio institucional e financeiro de entidades como o Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq). Criado em 1951, o órgão é fundamental na formulação de políticas de ciência, tecnologia e inovação, contribuindo para o desenvolvimento do país e para o reconhecimento internacional da pesquisa brasileira. Vinculado ao Ministério da Ciência, Tecnologia e Inovações (MCTI), o CNPq tem como objetivo fomentar a pesquisa científica, tecnológica e de inovação, além de promover a formação de recursos humanos qualificados em todas as áreas do conhecimento.

O Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) disponibiliza dados abertos que qualquer pessoa pode acessar, usar, modificar e compartilhar livremente para diferentes finalidades. Essa iniciativa segue a metodologia de publicação de dados governamentais em formatos reutilizáveis, com o objetivo de ampliar a transparência e incentivar a participação cidadã. Os dados utilizados neste trabalho referem-se a bolsas e projetos vigentes, reunindo informações sobre os pagamentos realizados entre 2003 e 2025.

A partir dessa base de dados, modelos de aprendizado de máquina podem ser utilizados na predição do fomento realizado pelo CNPq, permitindo a identificação de tendências históricas e o mapeamento de vieses na distribuição de recursos ao longo dos anos.

*  Bolsista Modalidade/Agência.  Universidade Tecnológica Federal do Paraná, Campo Mourão, Paraná, Brasil.  felgom@alunos.utfpr.edu.br.  4460710954552130.  0000-0000-0000-0001.

2 MATERIAL E MÉTODOS

2.1 Citações e Referências

2.2 Trabalhos Relacionados

2.2.1 Uso de Aprendizado de Máquina para Categorização Automática de Conjuntos de Dados de Portais de Dados Abertos

Nessa pesquisa, ([Rangel et al., 2020](#)) apresentam uma análise experimental focada na automatização da classificação de conjuntos de dados governamentais utilizando aprendizado de máquina supervisionado. Os autores extraíram metadados textuais, especificamente os nomes dos conjuntos de dados e os atributos de arquivos anexados (como colunas de tabelas CSV e GeoJSON) de portais baseados na plataforma CKAN. Após o tratamento dos dados com técnicas de Processamento de Linguagem Natural (PLN) — incluindo remoção de *stopwords* e estemização, os dados foram mapeados usando modelos de vetorização como *Bag of Words* (BoW) e TF-IDF. Foram testados os algoritmos Multinomial Naive Bayes (MNB) e Máquinas de Vetores de Suporte Lineares (SVM), sendo que o modelo SVM Linear combinado com a vetorização BoW binária obteve o melhor desempenho, alcançando uma acurácia de 58%. O estudo evidencia a viabilidade do uso de inteligência artificial sobre dados abertos governamentais para contornar a falta de padronização e otimizar a gestão pública de metadados.

2.2.2 Aplicação de Aprendizado de Máquina na Detecção de Fraudes Públicas

Em sua dissertação de mestrado, ([Lopes, 2019](#)) investiga a utilização de técnicas de aprendizado de máquina para identificar fraudes em contratos públicos a partir de dados abertos governamentais. O estudo utiliza informações provenientes do Portal de Dados Abertos, combinando registros de contratos públicos do Ministério do Planejamento com dados do Cadastro Nacional de Empresas Inidôneas e Suspensas (CEIS), mantido pela Controladoria-Geral da União (CGU). Após a etapa de preparação dos dados, foram construídas variáveis relacionadas às características das licitações, empresas contratadas e contratos firmados, sendo empregadas técnicas de seleção de atributos para reduzir a dimensionalidade do conjunto de dados. Na fase de modelagem, foram avaliados diferentes algoritmos de classificação, incluindo Regressão Logística, Árvores de Decisão, Random Forest, Gradient Boosting e LightGBM, com o objetivo de identificar contratos associados a empresas sancionadas. Os resultados demonstraram que técnicas de aprendizado de máquina são capazes de detectar padrões relacionados a fraudes em compras públicas, mesmo em cenários caracterizados por classes desbalanceadas e eventos raros. O trabalho evidencia o potencial da inteligência artificial como ferramenta de apoio à auditoria e ao controle de gastos públicos, contribuindo para aumentar a eficiência na identificação de irregularidades e na proteção do patrimônio público. ([Lopes, 2019](#))

2.3 Equações Matemáticas

3 RESULTADOS E DISCUSSÃO

4 CONCLUSÕES

Agradecimentos

Material suplementar

Disponibilidade de código

Conflito de interesse

REFERÊNCIAS

LOPES, Marco Antonio. **Aplicação de aprendizado de máquina na detecção de fraudes públicas**. 2019. Dissertação de Mestrado – Faculdade de Economia, Administração e Contabilidade, São Paulo. DOI: [10.11606/D.12.2020.tde-10022020-174317](https://doi.org/10.11606/D.12.2020.tde-10022020-174317). Disponível em: <https://teses.usp.br/teses/disponiveis/12/12139/tde-10022020-174317/>. Acesso em: 1 jun. 2026.

RANGEL, Mateus *et al.* Uso de Aprendizado de Máquina para Categorização Automática de Conjuntos de Dados de Portais de Dados Abertos. *In: ANAIS do VIII Workshop de Computação Aplicada em Governo Eletrônico*. Cuiabá: SBC, 2020. p. 120–131. DOI: [10.5753/wcge.2020.11263](https://doi.org/10.5753/wcge.2020.11263). Disponível em: <https://sol.sbc.org.br/index.php/wcge/article/view/11263>.